GMSC 金融风控评分卡建模总结报告

基于真实 Give Me Some Credit 数据的教学研究成果

项目阶段：第七阶段最终交付 | 口径：预测未来两年严重逾期概率

摘要

项目在有标签样本上按目标变量分层划分训练集、验证集和测试集。WOE + Logistic Regression 构成主评分卡；Random Forest 与 XGBoost 用作对照。模型选择只依据训练过程和验证集；冻结后测试集仅用于一次性泛化审计。

验证集综合比较显示 XGBoost 是最佳树模型挑战者，主评分卡仍保留 Logistic 路线。这个选择同时考虑概率校准、可解释性、复杂度与教学目标。所有策略结果均为训练集样本内模拟，不构成审批建议。

1 任务与数据治理

数据组	样本量	用途
训练集	105,000	拟合清洗、分箱、特征筛选与调参
验证集	22,500	模型选择与稳定性检查
测试集	22,500	冻结后一次性审计

原始数据由用户本地提供；无标签 Kaggle 测试文件不用于最终评价。模型目标 SeriousDlqin2yrs=1 表示未来两年发生严重逾期。项目不预测损失金额、收益，也不代表真实授信决策。

2 数据清洗与特征工程

第二阶段在训练集检查缺失、特殊值和风险分组，再将训练集拟合的规则应用于三组数据。第三阶段保留原始变量并形成 20 个非 WOE 候选特征；分箱、WOE 和 IV 仅在训练集拟合。验证集 PSI 不使用标签。

训练集月收入缺失 20,723 条，占 19.74%。缺失模式可能反映记录方式，不能直接解释为因果风险。部分逾期变量具有较高 IV，项目在后续筛选时复核冗余和业务意义。

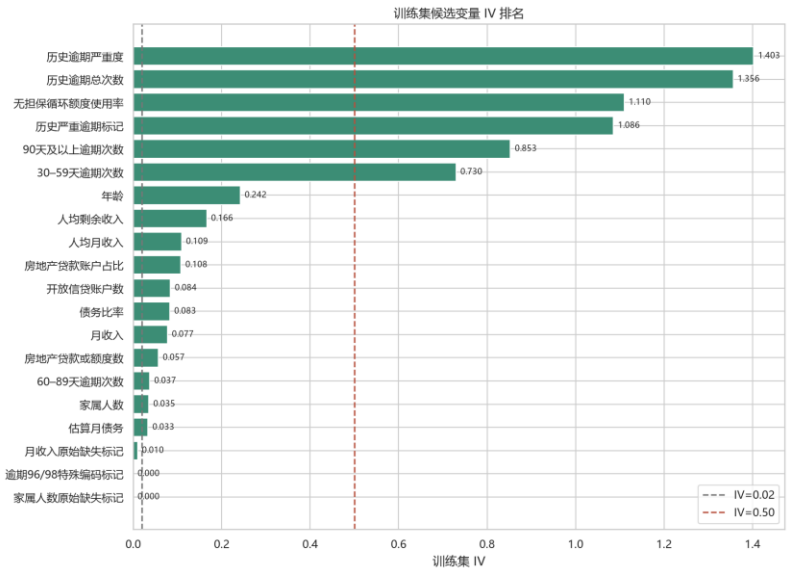


图 1 训练集候选变量 IV 排名

3 Logistic 主评分卡

第四阶段综合 IV、相关性、VIF、系数方向、显著性、稳定性和业务意义，最终采用“原始比例”方案，保留 8 个变量。评分参数为基准分 600、好坏 Odds 20:1、PDO 20；A–E 等级边界仅由训练集评分分布确定。

客户页同时呈现严重逾期概率、信用分、等级和变量贡献。总分与贡献分经过一致性核对；RF 与 XGBoost 仅提供概率对照。

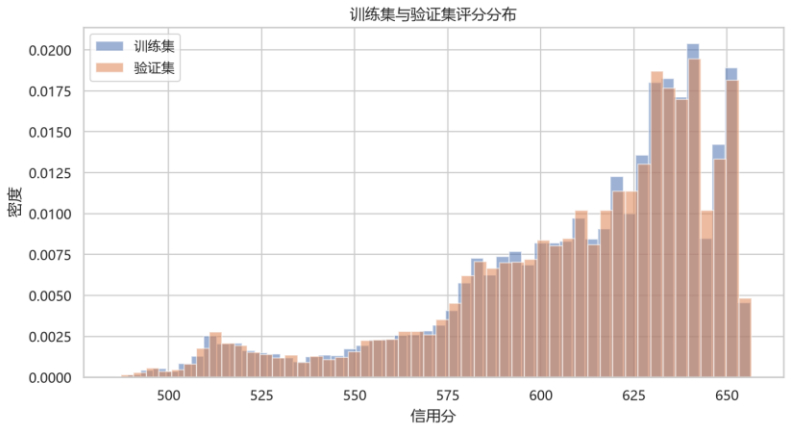


图 2 训练集评分分布

4 验证集模型比较

模型	AUC	KS	PR-AUC	F1	Brier
XGBoost	0.870	0.587	0.406	0.451	0.048
Random Forest	0.870	0.590	0.399	0.450	0.049
Logistic 评分卡	0.860	0.567	0.358	0.438	0.050

XGBoost 在验证集综合比较中领先，是最佳树模型挑战者；Logistic 主评分卡保留清晰的分箱、WOE 和积分贡献路径。Random Forest 的验证集校准截距略超项目设定门槛。模型结论不能只凭 AUC 得出。

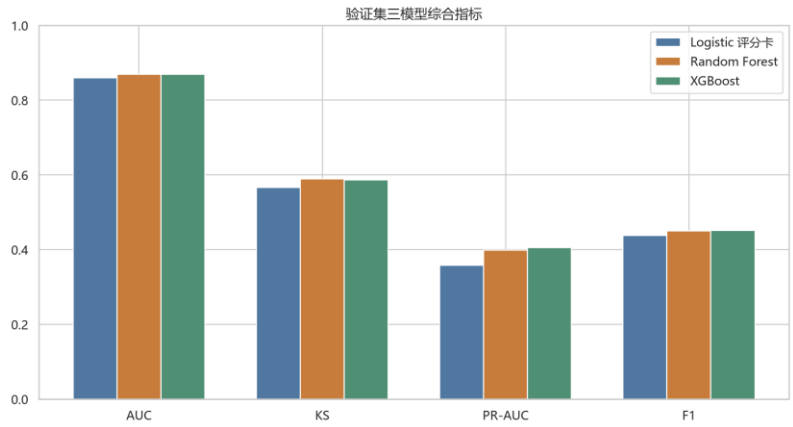


图 3 验证集三模型关键指标

5 冻结后测试审计

模型	AUC	KS	PR-AUC	F1	Brier
XGBoost	0.863	0.570	0.404	0.438	0.049
Random Forest	0.861	0.568	0.400	0.433	0.049
Logistic 评分卡	0.854	0.561	0.356	0.436	0.051

三模型、阈值和验证结论先写入 SHA-256 冻结清单，再读取测试标签开展一次审计。测试集表只报告泛化表现，不生成新的模型排名，不据此调参或改变主模型。

6 模型解释与策略模拟

树模型 SHAP 在严重逾期概率空间计算，RF 和 XGBoost 的最大加总误差分别为 1.70e-08 与 3.40e-07。局部解释仅展示第五阶段固定的代表客户，不对新输入客户重算 SHAP。

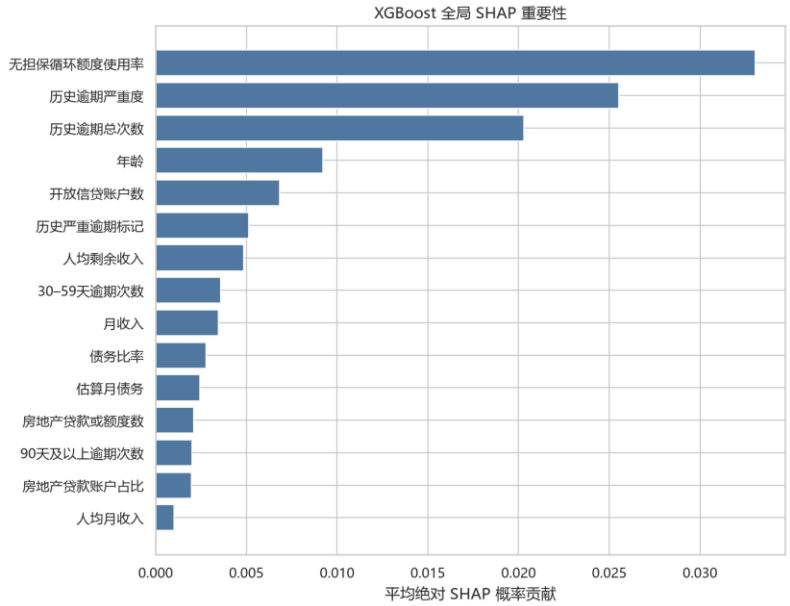


图 4 XGBoost 验证集 SHAP 全局重要性

以最低通过分 600 作教学示例，训练集样本内通过率为 69.80%，通过客户坏率为 1.73%，被拒坏客户捕获率为 81.89%。这些结果可能偏乐观，不能当作真实审批策略收益。

7 局限、复现与交付

数据来自公开竞赛，缺少真实授信规则、时间外样本和上线监控环境。分组风险、SHAP 与积分贡献描述统计或模型关联，不证明因果关系。冻结后的测试审计不得用于再选择模型。

项目使用 Python 3.11 和根目录 .venv；运行 `python -m pytest -q` 检查实现，双击 Windows 启动脚本打开本地八页面应用。原始数据、逐行数据、日志和序列化模型保持在本地，不进入版本库。

主要来源：reports/stage3_summary.json、reports/stage4_summary.json、reports/stage5_summary.json、models/stage5_frozen_manifest.json，以及四本阶段分析工作簿。冻结清单 SHA-256：9b879429bbcced4d683e055ec1ba3f08f5c4ddf1fa7f256e5517b7fdcab38429